15 Pandas

June 18, 2025

Creado por:

Isabel Maniega

1 Pandas, Temario

- 1. Vista de los datos
- 2. Selección
- 3. Setting
- 4. Missing values
- 5. Operaciones
- 6. Unión de dataframe
- 7. Grouping
- 8. Reshaping
- 9. Time Series
- 10. Categoricals
- 11. Plotting

2 Pandas

Contiene dos tipos de estructuras:

- Series: una matriz etiquetada unidimensional que contiene datos de cualquier tipo como números enteros, cadenas, objetos Python, etc.
- Dataframe: una estructura de datos bidimensional que contiene datos como una matriz bidimensional o una tabla con filas y columnas.

```
[1]: | # pip install pandas
```

```
[2]: from IPython import display
```

```
[3]: import pandas as pd import numpy as np
```

2.1 Creación de un dataframe

pd.DataFrame()

• A partir de Series:

```
[4]: # Series:
    s = pd.Series([1, 3, 5, np.nan, 6, 8])
[4]: 0
        1.0
        3.0
    1
    2
        5.0
    3
        NaN
    4
        6.0
    5
        8.0
    dtype: float64
[5]: # date_range(genera un rango de fecha apartir de un valor, marcando el númerou
    →de datos a generar (periods)
    dates = pd.date_range("20130101", periods=6)
    dates
[5]: DatetimeIndex(['2013-01-01', '2013-01-02', '2013-01-03', '2013-01-04',
                 '2013-01-05', '2013-01-06'],
                dtype='datetime64[ns]', freq='D')
[6]: df = pd.DataFrame(np.random.randn(6, 4), index=dates, columns=list("ABCD"))
[6]:
                    Α
                             В
                                      С
                                               D
    2013-01-01 1.454935 -0.218869 1.820150 -1.803966
    2013-01-03 -0.975626 -0.671088 0.514290 0.540713
    2013-01-04 0.970953 -2.358905 -0.991593 -0.900995
    [7]: # dtypes nos muestra de que tipo son los datos:
    df.dtypes
[7]: A
        float64
    В
        float64
    С
        float64
    D
        float64
    dtype: object
      • A partir de un diccionario:
[8]: notas = [10, 9, 5, 4, 8]
    alumnos = ["Paula", "Fermin", "Pedro", "Luis", "Ana"]
```

```
evaluacion = {"Alumnos": alumnos, "Notas": notas}
     df_eval = pd.DataFrame(evaluacion)
     df_eval
 [8]:
       Alumnos Notas
         Paula
                   10
     1 Fermin
                    9
         Pedro
     2
                    5
     3
          Luis
                    4
     4
           Ana
                    8
       • A partir de listas:
 [9]: df_evaluar = pd.DataFrame(alumnos, columns=["Alumnos"])
     df_evaluar
 [9]:
       Alumnos
         Paula
     1 Fermin
     2
         Pedro
          Luis
     3
     4
           Ana
     Otra forma...
[10]: df_evaluar = pd.DataFrame(list(zip(alumnos, notas)), columns=["Alumnos", __

¬"Notas"])
     df_evaluar
[10]:
       Alumnos Notas
         Paula
                   10
     1 Fermin
                    9
         Pedro
     2
                    5
     3
          Luis
                    4
           Ana
                    8
     2.2 Vista de los datos
[11]: # Muestra las primeras filas del dataframe, por defecto las 5 primeras
     df.head()
                                          С
[11]:
                       Α
                                 В
     2013-01-01 1.454935 -0.218869 1.820150 -1.803966
     2013-01-03 -0.975626 -0.671088 0.514290 0.540713
     2013-01-04 0.970953 -2.358905 -0.991593 -0.900995
```

```
[12]: df.head(2)
[12]:
                             В
                                     C
                     Α
     2013-01-01 1.454935 -0.218869 1.820150 -1.803966
     [13]: # Muestra las últimas filas de un dataframe, por defecto las 5 últimas:
     df.tail()
Γ13]:
                             В
                                     C
                     Α
     2013-01-03 -0.975626 -0.671088 0.514290 0.540713
     2013-01-04 0.970953 -2.358905 -0.991593 -0.900995
     2013-01-05  0.534581  -0.930495  1.116256  -0.388515
     2013-01-06 0.974511 -0.362095 -1.145968 -0.890391
[14]: df.tail(2)
[14]:
    2013-01-05 0.534581 -0.930495 1.116256 -0.388515
     [15]: # Muestra el valor de la primera columna que suele ser un valor único (id), en
     ⇔este ejemplo una fecha:
     df.index
[15]: DatetimeIndex(['2013-01-01', '2013-01-02', '2013-01-03', '2013-01-04',
                 '2013-01-05', '2013-01-06'],
                dtype='datetime64[ns]', freq='D')
[16]: # Muestra el nombre de las columnas:
     df.columns
[16]: Index(['A', 'B', 'C', 'D'], dtype='object')
[17]: # Podemos convertir un dataframe en una matriz de numpy con:
     df.to_numpy()
[17]: array([[ 1.45493465, -0.21886851, 1.82014986, -1.80396643],
           [-0.50038834, 0.2841034, -1.37428926, -1.45753791],
```

[-0.97562574, -0.67108764, 0.51428952, 0.54071329], [0.97095254, -2.3589046 , -0.99159251, -0.90099474],

```
[18]: # Para obtener los estadísticos más representativos usamos:
     df.describe()
[18]:
                                    C
                                             D
                           В
     count 6.000000 6.000000 6.000000 6.000000
           0.409828 -0.709558 -0.010192 -0.816782
     mean
     std
           0.947577 0.907690 1.342238 0.827504
          -0.975626 -2.358905 -1.374289 -1.803966
     min
     25%
         -0.241646 -0.865643 -1.107374 -1.318402
     50%
          0.752767 -0.516591 -0.238651 -0.895693
         0.973621 -0.254675 0.965764 -0.513984
     75%
           1.454935 0.284103 1.820150 0.540713
     max
[19]: # Podemos dar la vuelta a la tabla y poner lo que esta en filas en columnas y_{\perp}
      ⇔viceversa:
     df.T
[19]:
        2013-01-01 2013-01-02 2013-01-03 2013-01-04 2013-01-05 2013-01-06
     Α
         1.454935 -0.500388 -0.975626 0.970953
                                                     0.534581
                                                               0.974511
                  0.284103
     В
        -0.218869
                             -0.671088 -2.358905 -0.930495
                                                               -0.362095
     С
         1.820150 -1.374289
                             0.514290 -0.991593
                                                     1.116256
                                                               -1.145968
     D
        -1.803966
                  -1.457538
                               0.540713
                                        -0.900995
                                                    -0.388515
                                                               -0.890391
[20]: # Colocar los valores según el indice:
     df.sort_index(axis=1, ascending=False)
[20]:
                      D
                               С
                                        В
     2013-01-02 -1.457538 -1.374289 0.284103 -0.500388
     2013-01-04 -0.900995 -0.991593 -2.358905 0.970953
     2013-01-05 -0.388515 1.116256 -0.930495 0.534581
     2013-01-06 -0.890391 -1.145968 -0.362095 0.974511
[21]: # Ordenar los datos según una columna:
     df.sort_values(by="B")
[21]:
                               В
     2013-01-04 0.970953 -2.358905 -0.991593 -0.900995
     2013-01-05  0.534581  -0.930495  1.116256  -0.388515
     2013-01-03 -0.975626 -0.671088 0.514290 0.540713
```

[0.53458143, -0.93049496, 1.1162561, -0.3885155], [0.97451082, -0.36209531, -1.14596775, -0.89039059]])

```
2013-01-01 1.454935 -0.218869 1.820150 -1.803966
     Seleccion
    2.3
    2.4 GetItem()
    Selección de columna. Existen 3 formas de seleccionar una columna:
[22]: df['A']
[22]: 2013-01-01
                1.454935
     2013-01-02
                -0.500388
     2013-01-03
                -0.975626
     2013-01-04
                0.970953
     2013-01-05
                0.534581
     2013-01-06
                0.974511
    Freq: D, Name: A, dtype: float64
[23]: df.A
[23]: 2013-01-01
                1.454935
     2013-01-02
                -0.500388
     2013-01-03
               -0.975626
     2013-01-04
               0.970953
     2013-01-05
                0.534581
     2013-01-06
                0.974511
    Freq: D, Name: A, dtype: float64
[24]: df[['A']]
[24]:
     2013-01-01 1.454935
     2013-01-02 -0.500388
     2013-01-03 -0.975626
     2013-01-04 0.970953
     2013-01-05 0.534581
     2013-01-06 0.974511
    Selección de filas mediante slicing(:)
[25]: df[0:2]
[25]:
                             В
                                      С
                     Α
     2013-01-01 1.454935 -0.218869 1.820150 -1.803966
```

[26]: df ["20130103": "20130105"]

```
[26]:
                                   В
     2013-01-03 -0.975626 -0.671088 0.514290 0.540713
     2013-01-04 0.970953 -2.358905 -0.991593 -0.900995
     2013-01-05  0.534581 -0.930495  1.116256 -0.388515
     Selección con la función loc[] y at[]
[27]: # Filas que coinciden con una etiqueta, selección de la primera fila:
      df.loc[dates[0]]
[27]: A
          1.454935
      В
         -0.218869
      С
          1.820150
      D
         -1.803966
      Name: 2013-01-01 00:00:00, dtype: float64
[28]: # Seleccionar todas las filas de una determinada columna:
      df.loc[:, ['B', 'C']]
[28]:
     2013-01-01 -0.218869 1.820150
      2013-01-02 0.284103 -1.374289
      2013-01-03 -0.671088 0.514290
      2013-01-04 -2.358905 -0.991593
      2013-01-05 -0.930495 1.116256
      2013-01-06 -0.362095 -1.145968
[29]: # Seleccionar por filas y columnas:
      df.loc["20130103":"20130105", ['B', 'C']]
[29]:
      2013-01-03 -0.671088 0.514290
      2013-01-04 -2.358905 -0.991593
      2013-01-05 -0.930495 1.116256
[30]: | # Selectionar para un valor determinado -0.891699 (20130103, B):
      df.loc[dates[2], 'B']
[30]: np.float64(-0.6710876421267064)
[31]: df.at[dates[2], 'B']
[31]: np.float64(-0.6710876421267064)
     Selección por posicion: método iloc[] y iat[]
```

```
[32]: # Selección de una fila en posición 3:
     df.iloc[3]
[32]: A
        0.970953
       -2.358905
     В
     C -0.991593
         -0.900995
     D
     Name: 2013-01-04 00:00:00, dtype: float64
[33]: # Selección de una fila y columna por slicing:
     df.iloc[3:5, 1:3]
[33]:
                                C
                       В
     2013-01-04 -2.358905 -0.991593
     2013-01-05 -0.930495 1.116256
[34]: # Selección por lista de posiciones:
     # Filas: 1, 2, 4
     # Columnas: 0(A), 2(C)
     df.iloc[[1, 2, 4], [0, 2]]
[34]:
     2013-01-02 -0.500388 -1.374289
     2013-01-03 -0.975626 0.514290
     2013-01-05 0.534581 1.116256
[35]: # Selección por filas o columnas:
     df.iloc[1:3, :]
[35]:
                                В
                                          С
                       Α
     2013-01-03 -0.975626 -0.671088 0.514290 0.540713
[36]: df.iloc[:, 1:3]
[36]:
                       В
                                C
     2013-01-01 -0.218869 1.820150
     2013-01-02 0.284103 -1.374289
     2013-01-03 -0.671088 0.514290
     2013-01-04 -2.358905 -0.991593
     2013-01-05 -0.930495 1.116256
     2013-01-06 -0.362095 -1.145968
```

```
[37]: # Selectionar un valor concreto por posición (2013-01-03, 'B'):
     df.iloc[2, 1]
[37]: np.float64(-0.6710876421267064)
[38]: df.iat[2, 1]
[38]: np.float64(-0.6710876421267064)
     2.5 Boolean indexing
[39]: # Selección por comparativa:
     df[df['A'] >= 0.2]
[39]:
     2013-01-01 1.454935 -0.218869 1.820150 -1.803966
     2013-01-04 0.970953 -2.358905 -0.991593 -0.900995
     2013-01-05  0.534581  -0.930495  1.116256  -0.388515
     Método isin()
[40]: # Selección según una coincidencia (filtrado):
     df2 = pd.DataFrame(["one", "one", "two", "three", "four", "three"],

columns=['E'])
     df2[df2["E"].isin(["one", "four"])]
「40]:
           Ε
     0
         one
     1
         one
     4 four
     2.6 Setting (Modificacion del dataframe)
[41]: # Añadir Valores nuevo
     serie = pd.Series([1, 2, 3, 4, 5, 6], index=pd.date_range("20130101", __
       →periods=6))
     serie
[41]: 2013-01-01
                  1
                  2
     2013-01-02
     2013-01-03
                  3
```

2013-01-04

```
2013-01-06
                6
    Freq: D, dtype: int64
[42]: df['E'] = serie
    df
[42]:
                                    C
                                              Ε
                            В
                                            D
    2013-01-01 1.454935 -0.218869 1.820150 -1.803966
    2013-01-03 -0.975626 -0.671088 0.514290 0.540713 3
    2013-01-04 0.970953 -2.358905 -0.991593 -0.900995 4
    2013-01-05  0.534581  -0.930495  1.116256  -0.388515  5
    2013-01-06 0.974511 -0.362095 -1.145968 -0.890391 6
[43]: # Modificar valor por etiqueta
     # Se modifica el primer valor de df por O en la columna A:
    df.at[dates[0], "A"] = 0
    df
[43]:
                                            D E
                    Α
                            В
                                    C
    2013-01-01 0.000000 -0.218869 1.820150 -1.803966
    2013-01-03 -0.975626 -0.671088 0.514290 0.540713
    2013-01-04 0.970953 -2.358905 -0.991593 -0.900995 4
    2013-01-06  0.974511  -0.362095  -1.145968  -0.890391  6
[44]: # Modificación de valor por posición
     # Se modifica el primer valor de la columna B:
    df.iat[0, 1] = 0
    df
[44]:
                            В
                                    C
                                            D F.
    2013-01-01 0.000000 0.000000 1.820150 -1.803966
    2013-01-03 -0.975626 -0.671088 0.514290 0.540713 3
    2013-01-04 0.970953 -2.358905 -0.991593 -0.900995
    2013-01-06  0.974511  -0.362095  -1.145968  -0.890391  6
[45]: # Modificación asignada por Numpy usando array:
    df.loc[:, "D"] = np.array([5] * len(df))
    df
```

2013-01-05

5

```
[45]:
     2013-01-01 0.000000 0.000000 1.820150
                                          5.0
     5.0
     2013-01-03 -0.975626 -0.671088 0.514290 5.0
     2013-01-04 0.970953 -2.358905 -0.991593 5.0 4
     2013-01-05  0.534581 -0.930495  1.116256  5.0  5
     2013-01-06  0.974511  -0.362095  -1.145968  5.0  6
[46]: # Modificar según una condición (where):
     df2 = df.copy() # Realización de una copia del df
     df2[df2 > 0.1] = -df2
     df2
[46]:
                      Α
                               В
                                        C
                                            D E
     2013-01-01 0.000000 0.000000 -1.820150 -5.0 -1
     2013-01-02 -0.500388 -0.284103 -1.374289 -5.0 -2
     2013-01-03 -0.975626 -0.671088 -0.514290 -5.0 -3
     2013-01-04 -0.970953 -2.358905 -0.991593 -5.0 -4
     2013-01-05 -0.534581 -0.930495 -1.116256 -5.0 -5
     2013-01-06 -0.974511 -0.362095 -1.145968 -5.0 -6
    2.7 Missing values
[47]: # Creamos una columna nueva con valores nulos:
     df1 = df.reindex(index=dates[0:4], columns=list(df.columns))
     df1.loc[dates[2]:dates[3], "E"] = np.nan
     df1.at[dates[0], "D"] = np.nan
     print(df1)
                     Α
                              В
                                            D
                                                F.
    2013-01-01 0.000000 0.000000 1.820150 NaN
                                              1.0
    5.0
                                              2.0
    2013-01-03 -0.975626 -0.671088 0.514290 5.0
                                              NaN
    2013-01-04 0.970953 -2.358905 -0.991593 5.0 NaN
[48]: # Eliminamos los valores nulos con la función dropna(): eliminando cualquier
      ⇔fila que contenga valores nulos
     df_1 = df1.dropna(how="any")
     df_1
[48]:
```

```
[49]: # Rellenar valores nulos:

df_1 = df1.fillna(value=5)
df_1
```

```
[49]: A B C D E
2013-01-01 0.000000 0.000000 1.820150 5.0 1.0
2013-01-02 -0.500388 0.284103 -1.374289 5.0 2.0
2013-01-03 -0.975626 -0.671088 0.514290 5.0 5.0
2013-01-04 0.970953 -2.358905 -0.991593 5.0 5.0
```

```
[50]: # isna() nos muestra si en el df hay valores nulo o no, sustituyendo por unubooleano (True / False)

pd.isna(df1)
```

```
[50]:

A B C D E

2013-01-01 False False False True False

2013-01-02 False False False False False

2013-01-03 False False False False True

2013-01-04 False False False False True
```

2.8 Operaciones

En estos casos no tiene en cuenta los valores nulos.

```
[51]:
         notas_1 notas_2 notas_3
      0
               15
                         16
                                   17
      1
               16
                         21
                                   22
      2
               15
                         16
                                   15
      3
               17
                         16
                                   22
               14
                                   14
                         13
```

2.8.1 Tendencia Central

Media

Como calcular la media de las distintas notas:

```
[52]: media_1 = df["notas_1"].mean()
media_1
```

[52]: np.float64(15.5)

```
[53]: media_2 = df["notas_2"].mean()
      media_2
[53]: np.float64(16.8)
[54]: media_3 = df["notas_3"].mean()
      media_3
[54]: np.float64(17.6)
     Mediana
     Como calcular la mediana de las distintas notas:
[55]: mediana_1 = df["notas_1"].median()
      mediana_1
[55]: np.float64(15.0)
[56]: mediana_2 = df["notas_2"].median()
      mediana_2
[56]: np.float64(16.0)
[57]: mediana_3 = df["notas_3"].median()
      mediana_3
[57]: np.float64(16.0)
     Moda
     Como calcular la moda de las distintas notas:
[58]: moda_1 = df["notas_1"].mode()
      moda_1
[58]: 0
           14
      Name: notas_1, dtype: int64
[59]: moda_2 = df["notas_2"].mode()
      moda_2
[59]: 0
           15
      Name: notas_2, dtype: int64
[60]: moda_3 = df["notas_3"].mode()
      moda_3
```

```
[60]: 0
           15
      Name: notas_3, dtype: int64
[61]: df.notas_3.value_counts()
[61]: notas_3
      15
      22
            2
      16
            2
      17
            1
      14
            1
      24
      Name: count, dtype: int64
     Resultados Nota_1:
[62]: print(f"Media: {media_1}, Mediana: {mediana_1}, Moda: \n{moda_1}")
     Media: 15.5, Mediana: 15.0, Moda:
     0
          14
           15
     Name: notas_1, dtype: int64
     Resultados Nota 2:
[63]: print(f"Media: {media_2}, Mediana: {mediana_2}, Moda: \n{moda_2}")
     Media: 16.8, Mediana: 16.0, Moda:
          15
           16
     Name: notas_2, dtype: int64
     Resultados Nota_2:
[64]: print(f"Media: {media_3}, Mediana: {mediana_3}, Moda: \n{moda_3}")
     Media: 17.6, Mediana: 16.0, Moda:
          15
     Name: notas_3, dtype: int64
     Varianza
     Se calcula la cuasi-varianza:
                                       S^2 = \frac{\sum_{i=1}^{n} (x_i - X)^2}{n-1}
[65]: var_1 = df["notas_1"].var()
      var_1
```

[65]: np.float64(14.5)

```
[66]: var_2 = df["notas_2"].var()
var_2
```

[66]: np.float64(8.39999999999999)

```
[67]: var_3 = df["notas_3"].var()
var_3
```

[67]: np.float64(13.15555555555557)

Si queremos calcular la varianza, utilizamos el argumento ddof=0. El denominador en la fórmula será entonces n-ddof=0:

```
[68]: var_1 = df["notas_1"].var(ddof=0)
var_1
```

[68]: np.float64(13.05)

Desviación típica

En python, utilizamos el método .std() para calcular la cuasi-desviación típica. Para calcular la desviación típica, nuevamente utilizamos ddof=0.

$$S^=\sqrt{S^2}$$

```
[69]: std_1 = df["notas_1"].std()
std_1
```

[69]: np.float64(3.8078865529319543)

```
[70]: std_2 = df["notas_2"].std()
std_2
```

[70]: np.float64(2.8982753492378874)

```
[71]: std_3 = df["notas_3"].std()
std_3
```

[71]: np.float64(3.6270588023294517)

Si queremos calcular la varianza, utilizamos el argumento ddof=0. El denominador en la fórmula será entonces n-ddof=0:

```
[72]: std_1 = df["notas_1"].std(ddof=0)
std_1
```

[72]: np.float64(3.6124783736376886)

Máximo y mínimo

```
[73]: max_1 = df["notas_1"].max()
    min_1 = df["notas_1"].min()
    print(max_1, min_1)

25 10

[74]: max_2 = df["notas_2"].max()
    min_2 = df["notas_2"].min()
    print(max_2, min_2)

22 13

[75]: max_3 = df["notas_3"].max()
    min_3 = df["notas_3"].min()
    print(max_3, min_3)
```

24 14

3 RESUMEN

Notas 1 Notas 2 Notas 3 Media 15.5 16.8 17.6 Mediana 15.0 16.0 16.0 Moda 14/15 15/16 15.0 std 3.807 2.90 3.63 max 25 22 24 min 10 13 14

```
[76]: df.describe()
```

```
[76]:
              notas_1
                         notas_2
                                    notas_3
                       10.000000 10.000000
            10.000000
      count
            15.500000
     mean
                       16.800000 17.600000
             3.807887
                        2.898275
                                   3.627059
      std
     min
             10.000000
                       13.000000 14.000000
     25%
            14.000000
                       15.000000 15.000000
     50%
             15.000000
                       16.000000 16.000000
     75%
            15.750000
                       18.250000 20.750000
             25.000000
                       22.000000 24.000000
     max
```

3.1 Union de dataframe

```
[77]: iris = pd.read_csv('./files/Iris.csv')
iris = iris.drop(['Id'], axis=1)
iris_setosa = iris[0:50]
iris_setosa
```

```
[77]:
          SepalLengthCm SepalWidthCm PetalLengthCm PetalWidthCm
                                                                          Species
      0
                    5.1
                                  3.5
                                                  1.4
                                                                0.2 Iris-setosa
                    4.9
                                  3.0
                                                  1.4
                                                                0.2 Iris-setosa
      1
      2
                    4.7
                                  3.2
                                                  1.3
                                                                0.2 Iris-setosa
      3
                    4.6
                                  3.1
                                                  1.5
                                                                0.2 Iris-setosa
                                                                0.2 Iris-setosa
      4
                    5.0
                                  3.6
                                                  1.4
      5
                    5.4
                                  3.9
                                                  1.7
                                                                0.4 Iris-setosa
```

6	4.6	3.4	1.4	0.3	Iris-setosa
7	5.0	3.4	1.5	0.2	Iris-setosa
8	4.4	2.9	1.4	0.2	Iris-setosa
9	4.9	3.1	1.5	0.1	Iris-setosa
10	5.4	3.7	1.5	0.2	Iris-setosa
11	4.8	3.4	1.6	0.2	Iris-setosa
12	4.8	3.0	1.4	0.1	Iris-setosa
13	4.3	3.0	1.1	0.1	Iris-setosa
14	5.8	4.0	1.2	0.2	Iris-setosa
15	5.7	4.4	1.5	0.4	Iris-setosa
16	5.4	3.9	1.3	0.4	Iris-setosa
17	5.1	3.5	1.4	0.3	Iris-setosa
18	5.7	3.8	1.7	0.3	Iris-setosa
19	5.1	3.8	1.5	0.3	Iris-setosa
20	5.4	3.4	1.7	0.2	Iris-setosa
21	5.1	3.7	1.5	0.4	Iris-setosa
22	4.6	3.6	1.0	0.2	Iris-setosa
23	5.1	3.3	1.7	0.5	Iris-setosa
24	4.8	3.4	1.9	0.2	Iris-setosa
25	5.0	3.0	1.6	0.2	Iris-setosa
26	5.0	3.4	1.6	0.4	Iris-setosa
27	5.2	3.5	1.5	0.2	Iris-setosa
28	5.2	3.4	1.4	0.2	Iris-setosa
29	4.7	3.2	1.6	0.2	Iris-setosa
30	4.8	3.1	1.6	0.2	Iris-setosa
31	5.4	3.4	1.5	0.4	Iris-setosa
32	5.2	4.1	1.5	0.1	Iris-setosa
33	5.5	4.2	1.4	0.2	Iris-setosa
34	4.9	3.1	1.5	0.1	Iris-setosa
35	5.0	3.2	1.2	0.2	Iris-setosa
36	5.5	3.5	1.3	0.2	Iris-setosa
37	4.9	3.1	1.5	0.1	Iris-setosa
38	4.4	3.0	1.3	0.2	Iris-setosa
39	5.1	3.4	1.5	0.2	Iris-setosa
40	5.0	3.5	1.3	0.3	Iris-setosa
41	4.5	2.3	1.3	0.3	Iris-setosa
42	4.4	3.2	1.3	0.2	Iris-setosa
43	5.0	3.5	1.6	0.6	Iris-setosa
44	5.1	3.8	1.9	0.4	Iris-setosa
45	4.8	3.0	1.4	0.3	Iris-setosa
46	5.1	3.8	1.6	0.2	Iris-setosa
47	4.6	3.2	1.4	0.2	Iris-setosa
48	5.3	3.7	1.5	0.2	Iris-setosa
49	5.0	3.3	1.4	0.2	Iris-setosa

[78]: iris_virginica = iris[100:] iris_virginica

[78]:	SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm	Species
100	6.3	3.3	6.0	2.5	Iris-virginica
101	5.8	2.7	5.1	1.9	Iris-virginica
102	7.1	3.0	5.9	2.1	Iris-virginica
103	6.3	2.9	5.6	1.8	Iris-virginica
104	6.5	3.0	5.8	2.2	Iris-virginica
105	7.6	3.0	6.6	2.1	Iris-virginica
106	4.9	2.5	4.5	1.7	Iris-virginica
107	7.3	2.9	6.3	1.8	Iris-virginica
108	6.7	2.5	5.8	1.8	Iris-virginica
109	7.2	3.6	6.1	2.5	Iris-virginica
110	6.5	3.2	5.1	2.0	Iris-virginica
111	6.4	2.7	5.3	1.9	Iris-virginica
112	6.8	3.0	5.5	2.1	Iris-virginica
113	5.7	2.5	5.0	2.0	Iris-virginica
114	5.8	2.8	5.1	2.4	Iris-virginica
115	6.4	3.2	5.3	2.3	Iris-virginica
116	6.5	3.0	5.5	1.8	Iris-virginica
117	7.7	3.8	6.7	2.2	Iris-virginica
118	7.7	2.6	6.9	2.3	Iris-virginica
119	6.0	2.2	5.0	1.5	Iris-virginica
120	6.9	3.2	5.7	2.3	Iris-virginica
121	5.6	2.8	4.9	2.0	Iris-virginica
122	7.7	2.8	6.7	2.0	Iris-virginica
123	6.3	2.7	4.9	1.8	Iris-virginica
124	6.7	3.3	5.7	2.1	Iris-virginica
125	7.2	3.2	6.0	1.8	Iris-virginica
126	6.2	2.8	4.8	1.8	Iris-virginica
127	6.1	3.0	4.9	1.8	Iris-virginica
128	6.4	2.8	5.6	2.1	Iris-virginica
129	7.2	3.0	5.8	1.6	Iris-virginica
130	7.4	2.8	6.1	1.9	Iris-virginica
131	7.9	3.8	6.4	2.0	Iris-virginica
132 133	6.4 6.3	2.8 2.8	5.6 5.1	2.2 1.5	Iris-virginica
					Iris-virginica
134 135	6.1 7.7	2.6 3.0	5.6 6.1	1.4	Iris-virginica Iris-virginica
136	6.3	3.4	5.6	2.3	•
137	6.4	3.1	5.5	2.4 1.8	Iris-virginica
	6.0				Iris-virginica
138	6.9	3.0	4.8 5.4	1.8	Iris-virginica
139 140	6.7	3.1 3.1	5.4	2.1	Iris-virginica Iris-virginica
140	6.9	3.1	5.1	2.4	•
141	5.8	2.7	5.1	2.3 1.9	Iris-virginica
142	6.8	3.2	5.9	2.3	Iris-virginica
143	6.7	3.3	5.7	2.5	Iris-virginica
					Iris-virginica
145	6.7	3.0	5.2	2.3	Iris-virginica

```
1.9 Iris-virginica
146
              6.3
                           2.5
                                          5.0
147
              6.5
                           3.0
                                          5.2
                                                       2.0 Iris-virginica
148
                                                       2.3 Iris-virginica
              6.2
                           3.4
                                          5.4
149
              5.9
                           3.0
                                          5.1
                                                        1.8 Iris-virginica
```

[79]: iris_versicolor = pd.read_json('./files/iris_versicolor.json')
iris_versicolor

[79]:	${\tt SepalLengthCm}$	${\tt SepalWidthCm}$	${\tt PetalLengthCm}$	${\tt PetalWidthCm}$	Species
0	7.0	3.2	4.7	1.4	Iris-versicolor
1	6.4	3.2	4.5	1.5	Iris-versicolor
2	6.9	3.1	4.9	1.5	Iris-versicolor
3	5.5	2.3	4.0	1.3	Iris-versicolor
4	6.5	2.8	4.6	1.5	Iris-versicolor
5	5.7	2.8	4.5	1.3	Iris-versicolor
6	6.3	3.3	4.7	1.6	Iris-versicolor
7	4.9	2.4	3.3	1.0	Iris-versicolor
8	6.6	2.9	4.6	1.3	Iris-versicolor
9	5.2	2.7	3.9	1.4	Iris-versicolor
10	5.0	2.0	3.5	1.0	Iris-versicolor
11	5.9	3.0	4.2	1.5	Iris-versicolor
12	6.0	2.2	4.0	1.0	Iris-versicolor
13	6.1	2.9	4.7	1.4	Iris-versicolor
14	5.6	2.9	3.6	1.3	Iris-versicolor
15	6.7	3.1	4.4	1.4	Iris-versicolor
16	5.6	3.0	4.5	1.5	Iris-versicolor
17	5.8	2.7	4.1	1.0	Iris-versicolor
18	6.2	2.2	4.5	1.5	Iris-versicolor
19	5.6	2.5	3.9	1.1	Iris-versicolor
20	5.9	3.2	4.8	1.8	Iris-versicolor
21	6.1	2.8	4.0	1.3	Iris-versicolor
22	6.3	2.5	4.9	1.5	Iris-versicolor
23	6.1	2.8	4.7	1.2	Iris-versicolor
24	6.4	2.9	4.3	1.3	Iris-versicolor
25	6.6	3.0	4.4	1.4	Iris-versicolor
26	6.8	2.8	4.8	1.4	Iris-versicolor
27	6.7	3.0	5.0	1.7	Iris-versicolor
28	6.0	2.9	4.5	1.5	Iris-versicolor
29	5.7	2.6	3.5	1.0	Iris-versicolor
30	5.5	2.4	3.8	1.1	Iris-versicolor
31	5.5	2.4	3.7	1.0	Iris-versicolor
32	5.8	2.7	3.9	1.2	Iris-versicolor
33	6.0	2.7	5.1	1.6	Iris-versicolor
34	5.4	3.0	4.5	1.5	Iris-versicolor
35	6.0	3.4	4.5	1.6	Iris-versicolor
36	6.7	3.1	4.7	1.5	Iris-versicolor
37	6.3	2.3	4.4	1.3	Iris-versicolor

38	5.6	3.0	4.1	1.3	Iris-versicolor
39	5.5	2.5	4.0	1.3	Iris-versicolor
40	5.5	2.6	4.4	1.2	Iris-versicolor
41	6.1	3.0	4.6	1.4	Iris-versicolor
42	5.8	2.6	4.0	1.2	Iris-versicolor
43	5.0	2.3	3.3	1.0	Iris-versicolor
44	5.6	2.7	4.2	1.3	Iris-versicolor
45	5.7	3.0	4.2	1.2	Iris-versicolor
46	5.7	2.9	4.2	1.3	Iris-versicolor
47	6.2	2.9	4.3	1.3	Iris-versicolor
48	5.1	2.5	3.0	1.1	Iris-versicolor
49	5.7	2.8	4.1	1.3	Iris-versicolor

3.2 concat()

```
[80]: # Unión de varios dataframe por nombre de columna, los apendiza al final:

dfs = [iris_setosa, iris_virginica, iris_versicolor]
    iris_concat = pd.concat(dfs)
    iris_concat
```

[80]:	${\tt SepalLengthCm}$	${\tt SepalWidthCm}$	${\tt PetalLengthCm}$	${\tt PetalWidthCm}$	Species
0	5.1	3.5	1.4	0.2	Iris-setosa
1	4.9	3.0	1.4	0.2	Iris-setosa
2	4.7	3.2	1.3	0.2	Iris-setosa
3	4.6	3.1	1.5	0.2	Iris-setosa
4	5.0	3.6	1.4	0.2	Iris-setosa
	•••	•••	•••	•••	•••
45	5.7	3.0	4.2	1.2	Iris-versicolor
46	5.7	2.9	4.2	1.3	Iris-versicolor
47	6.2	2.9	4.3	1.3	Iris-versicolor
48	5.1	2.5	3.0	1.1	Iris-versicolor
49	5.7	2.8	4.1	1.3	Iris-versicolor

[150 rows x 5 columns]

```
[81]: display.Image('./images/merging_concat_basic.png')
```

[81]:

		df1					Result		
	А	В	С	D					
0	AD	BO	В	D0		Α	В	U	D
1	A1	B1	П	D1	0	AD	BO	8	D0
2	A2	B2	Ŋ	D2	1	A1	B1	а	D1
3	A3	В3	ß	D3	2	A2	B2	a	D2
		df2							-
	А	В	С	D	3	A3	B3	O	D3
4	A4	B4	C4	D4	4	A4	B4	C4	D4
5	A5	B5	0	D5	5	A5	B5	O	D5
6	Aß	B6	8	D6	6	Aß	B6	C6	D6
7	A7	В7	C7	D7	7	A7	B7	a	D7
		df3					-		-
	А	В	С	D	8	AB	B8	СВ	D8
8	AB	B8	СВ	D8	9	A9	B9	9	D9
9	A9	B9	C9	D9	10	A10	B10	ПO	D10
10	A10	B10	C10	D10	11	A11	B11	а1	D11
11	A11	B11	C11	D11					

```
[82]: iris = pd.read_csv('./files/Iris.csv')
iris_medidas = iris.iloc[:, 0:4]
iris_medidas
```

[82]:		Id	SepalLengthCm	SepalWidthCm	PetalLengthCm
	0	1	5.1	3.5	1.4
	1	2	4.9	3.0	1.4
	2	3	4.7	3.2	1.3
	3	4	4.6	3.1	1.5
	4	5	5.0	3.6	1.4
			•••	•••	•••
	145	146	6.7	3.0	5.2
	146	147	6.3	2.5	5.0
	147	148	6.5	3.0	5.2
	148	149	6.2	3.4	5.4
	149	150	5.9	3.0	5.1

[150 rows x 4 columns]

[83]: iris_especies = iris[['Species']]

```
iris_especies
[83]:
                  Species
      0
              Iris-setosa
      1
              Iris-setosa
              Iris-setosa
      3
              Iris-setosa
      4
              Iris-setosa
      145
         Iris-virginica
      146 Iris-virginica
      147 Iris-virginica
      148 Iris-virginica
          Iris-virginica
      [150 rows x 1 columns]
[84]: # Apendizar una columna nueva usando concat:
      # axis=1 elegimos el eje
      # join='inner' elegimos el tipo de unión:
      new_setosa = pd.concat([iris_medidas, iris_especies], axis=1, join='inner')
      new_setosa
[84]:
               SepalLengthCm SepalWidthCm PetalLengthCm
                                                                    Species
            Ιd
      0
             1
                          5.1
                                         3.5
                                                        1.4
                                                                Iris-setosa
                                                        1.4
      1
             2
                          4.9
                                         3.0
                                                                Iris-setosa
      2
                          4.7
                                         3.2
                                                        1.3
             3
                                                                Iris-setosa
      3
             4
                          4.6
                                         3.1
                                                        1.5
                                                                Iris-setosa
      4
             5
                          5.0
                                         3.6
                                                        1.4
                                                                Iris-setosa
      145 146
                          6.7
                                         3.0
                                                        5.2 Iris-virginica
                          6.3
                                         2.5
                                                        5.0 Iris-virginica
      146 147
      147
          148
                          6.5
                                         3.0
                                                        5.2 Iris-virginica
                          6.2
      148
          149
                                         3.4
                                                        5.4 Iris-virginica
                          5.9
                                                        5.1 Iris-virginica
      149
          150
                                         3.0
      [150 rows x 5 columns]
[85]: display.Image('./images/merging_concat_mixed.png')
[85]:
```

	df1			S	s1 Result							
	А	В	С	D		х		А	В	С	D	х
0	AD	BO	8	D0	0	XD	0	AD	В0	8	DO	XD
1	Al	B1	đ	D1	1	хі	1	A1	B1	đ	D1	хі
2	A2	B2	U	D2	2	X2	2	A2	B2	U	D2	X2
3	A3	В3	O	D3	3	ХЗ	3	АЗ	В3	Ü	D3	ХЗ

3.3 merge()

many-to-many: El método merge une dos dataframe por el Id de cada una de las filas

```
[86]: new_species = iris.loc[:, ['Id', 'Species']]
new_species
```

```
[86]:
                        Species
            Ιd
      0
             1
                    Iris-setosa
      1
             2
                    Iris-setosa
      2
             3
                    Iris-setosa
      3
             4
                    Iris-setosa
      4
             5
                    Iris-setosa
      145
           146
                Iris-virginica
                Iris-virginica
      146
           147
      147
                Iris-virginica
           148
      148
           149
                Iris-virginica
      149
           150
                Iris-virginica
```

[150 rows x 2 columns]

```
[87]: new_setosa = pd.merge(iris_medidas, new_species, on='Id')
new_setosa
```

[87]:		Id	SepalLengthCm	${\tt SepalWidthCm}$	PetalLengthCm	Species
C)	1	5.1	3.5	1.4	Iris-setosa
1	1	2	4.9	3.0	1.4	Iris-setosa
2	2	3	4.7	3.2	1.3	Iris-setosa
3	3	4	4.6	3.1	1.5	Iris-setosa
4	1	5	5.0	3.6	1.4	Iris-setosa
		•••	•••	•••	•••	•••
1	145	146	6.7	3.0	5.2	Iris-virginica
1	146	147	6.3	2.5	5.0	Iris-virginica
1	147	148	6.5	3.0	5.2	Iris-virginica
1	148	149	6.2	3.4	5.4	Iris-virginica

149 150 5.9 3.0 5.1 Iris-virginica

[150 rows x 5 columns]

[88]: display.Image('./images/merging_merge_on_key.png')

[88]: left right Result

	key	А	В		key	С	D		key	А	В	С	D
0	KD	AD	BO	0	KD	В	D0	0	KD	AD	BO	В	D0
1	кт	A1	B1	1	кі	а	D1	1	кі	A1	B1	а	D1
2	K2	A2	B2	2	K2	ū	D2	2	K2	A2	B2	Q	D2
3	КЗ	EA.	В3	3	КЗ	СЗ	D3	3	КЗ	EA.	В3	СЗ	D3

Se puede añadir un parámetro que se llama how, donde se especifica el tipo de unión de los dataframes, para ello, nos basamos en la siguiente tabla para relacionarlos con los comandos SQL:

Merge method	SQL Join Name	Description
left	LEFT OUTER JOIN	Use keys from left frame only
right	RIGHT OUTER JOIN	Use keys from right frame only
outer	FULL OUTER JOIN	Use union of keys from both frames
inner	INNER JOIN	Use intersection of keys from both frames
cross	CROSS JOIN	Create the cartesian product of rows of both frames

[89]: new_setosa = pd.merge(iris_medidas, new_species, how='left', on='Id')
new_setosa

[89]:		Id	SepalLengthCm	${\tt SepalWidthCm}$	PetalLengthCm	Species
	0	1	5.1	3.5	1.4	Iris-setosa
	1	2	4.9	3.0	1.4	Iris-setosa
	2	3	4.7	3.2	1.3	Iris-setosa
	3	4	4.6	3.1	1.5	Iris-setosa
	4	5	5.0	3.6	1.4	Iris-setosa
			•••	•••	•••	•••
	145	146	6.7	3.0	5.2	Iris-virginica
	146	147	6.3	2.5	5.0	Iris-virginica
	147	148	6.5	3.0	5.2	Iris-virginica
	148	149	6.2	3.4	5.4	Iris-virginica
	149	150	5.9	3.0	5.1	Iris-virginica

[150 rows x 5 columns]

```
[90]: new_setosa = pd.merge(iris_medidas, new_species, how='right', on='Id')
      new_setosa
[90]:
            Ιd
                SepalLengthCm SepalWidthCm PetalLengthCm
                                                                      Species
                                          3.5
      0
             1
                           5.1
                                                          1.4
                                                                  Iris-setosa
      1
             2
                           4.9
                                          3.0
                                                          1.4
                                                                  Iris-setosa
      2
                           4.7
                                          3.2
                                                          1.3
             3
                                                                  Iris-setosa
      3
             4
                           4.6
                                          3.1
                                                          1.5
                                                                  Iris-setosa
      4
                           5.0
                                          3.6
                                                          1.4
                                                                  Iris-setosa
      . .
      145
           146
                           6.7
                                          3.0
                                                          5.2 Iris-virginica
      146
           147
                           6.3
                                          2.5
                                                          5.0 Iris-virginica
      147
           148
                           6.5
                                          3.0
                                                          5.2 Iris-virginica
      148
           149
                           6.2
                                          3.4
                                                          5.4 Iris-virginica
                           5.9
      149
          150
                                          3.0
                                                          5.1
                                                               Iris-virginica
      [150 rows x 5 columns]
[91]: new_setosa = pd.merge(iris_medidas, new_species, how='inner', on='Id')
      new_setosa
[91]:
                SepalLengthCm SepalWidthCm PetalLengthCm
                                                                      Species
                           5.1
      0
             1
                                          3.5
                                                          1.4
                                                                  Iris-setosa
      1
             2
                           4.9
                                          3.0
                                                          1.4
                                                                  Iris-setosa
      2
             3
                           4.7
                                          3.2
                                                          1.3
                                                                  Iris-setosa
      3
             4
                           4.6
                                          3.1
                                                          1.5
                                                                  Iris-setosa
      4
             5
                           5.0
                                          3.6
                                                          1.4
                                                                  Iris-setosa
      145
                           6.7
                                                          5.2 Iris-virginica
           146
                                          3.0
                           6.3
                                          2.5
                                                          5.0 Iris-virginica
      146
           147
                                                          5.2 Iris-virginica
      147
           148
                           6.5
                                          3.0
                           6.2
      148
           149
                                          3.4
                                                          5.4 Iris-virginica
      149
           150
                           5.9
                                          3.0
                                                          5.1
                                                               Iris-virginica
      [150 rows x 5 columns]
[92]: new_setosa = pd.merge(iris_medidas, new_species, how='outer', on='Id')
      new_setosa
[92]:
                SepalLengthCm SepalWidthCm
                                              PetalLengthCm
                                                                      Species
            Ιd
      0
             1
                           5.1
                                          3.5
                                                          1.4
                                                                  Iris-setosa
      1
             2
                           4.9
                                          3.0
                                                          1.4
                                                                  Iris-setosa
      2
             3
                           4.7
                                          3.2
                                                          1.3
                                                                  Iris-setosa
      3
             4
                           4.6
                                          3.1
                                                          1.5
                                                                  Iris-setosa
      4
             5
                           5.0
                                          3.6
                                                          1.4
                                                                  Iris-setosa
      145
           146
                           6.7
                                          3.0
                                                          5.2 Iris-virginica
```

146	147	6.3	2.5	5.0	Iris-virginica
147	148	6.5	3.0	5.2	Iris-virginica
148	149	6.2	3.4	5.4	Iris-virginica
149	150	5.9	3.0	5.1	Iris-virginica

[150 rows x 5 columns]

```
[93]: new_setosa = pd.merge(iris_medidas, new_species, how='cross')
new_setosa
```

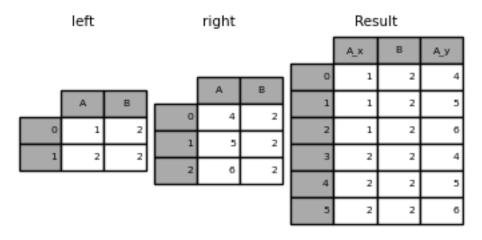
[93]:	Id_x	${\tt SepalLengthCm}$	${\tt SepalWidthCm}$	${\tt PetalLengthCm}$	<pre>Id_y</pre>	Species
0	1	5.1	3.5	1.4	1	Iris-setosa
1	1	5.1	3.5	1.4	2	Iris-setosa
2	1	5.1	3.5	1.4	3	Iris-setosa
3	1	5.1	3.5	1.4	4	Iris-setosa
4	1	5.1	3.5	1.4	5	Iris-setosa
•••	•••	•••	•••			••
22495	150	5.9	3.0	5.1	146	Iris-virginica
22496	150	5.9	3.0	5.1	147	Iris-virginica
22497	150	5.9	3.0	5.1	148	Iris-virginica
22498	150	5.9	3.0	5.1	149	Iris-virginica
22499	150	5.9	3.0	5.1	150	Iris-virginica

[22500 rows x 6 columns]

```
[94]: # Si no existe la clave la duplica en el caso how=cross:

display.Image('./images/merging_merge_on_key_dup.png')
```

[94]:



3.4 join()

```
[95]: iris_medidas
                 SepalLengthCm SepalWidthCm PetalLengthCm
[95]:
            Ιd
                           5.1
      0
              1
                                           3.5
                            4.9
      1
             2
                                           3.0
                                                           1.4
                           4.7
                                           3.2
      2
              3
                                                           1.3
      3
             4
                            4.6
                                           3.1
                                                           1.5
      4
             5
                            5.0
                                           3.6
                                                           1.4
      145
                           6.7
                                           3.0
                                                           5.2
           146
      146
           147
                            6.3
                                           2.5
                                                           5.0
                            6.5
                                           3.0
                                                           5.2
      147
           148
                            6.2
                                           3.4
                                                           5.4
      148
           149
      149
           150
                            5.9
                                           3.0
                                                           5.1
      [150 rows x 4 columns]
[96]: iris_especies
[96]:
                   Species
               Iris-setosa
      1
               Iris-setosa
      2
              Iris-setosa
      3
               Iris-setosa
      4
               Iris-setosa
      . .
           Iris-virginica
      145
      146
           Iris-virginica
      147
           Iris-virginica
      148
           Iris-virginica
      149
           Iris-virginica
      [150 rows x 1 columns]
[97]: iris_2 = iris_medidas.join(iris_especies)
      iris_2
[97]:
                SepalLengthCm SepalWidthCm PetalLengthCm
                                                                        Species
            Ιd
      0
             1
                           5.1
                                           3.5
                                                           1.4
                                                                   Iris-setosa
      1
             2
                            4.9
                                           3.0
                                                           1.4
                                                                   Iris-setosa
      2
             3
                            4.7
                                           3.2
                                                           1.3
                                                                   Iris-setosa
      3
             4
                            4.6
                                           3.1
                                                           1.5
                                                                   Iris-setosa
      4
             5
                            5.0
                                           3.6
                                                           1.4
                                                                   Iris-setosa
      145
           146
                           6.7
                                           3.0
                                                           5.2 Iris-virginica
      146
           147
                            6.3
                                           2.5
                                                           5.0 Iris-virginica
```

147	148	6.5	3.0	5.2	Iris-virginica
148	149	6.2	3.4	5.4	Iris-virginica
149	150	5.9	3.0	5.1	Iris-virginica

[150 rows x 5 columns]

También se le puede añadir los parámetros de how y on, igual que se hace con el método merge()

3.5 Grouping

Por "group by" nos referimos a un proceso que implica uno o más de los siguientes pasos:

- Splitting los datos en grupos según ciertos criterios
- Applying una función a cada grupo de forma independiente

```
• Combining los resultados en una estructura de datos
[98]: iris
[98]:
                  SepalLengthCm
                                   {\tt SepalWidthCm}
                                                   PetalLengthCm
                                                                    PetalWidthCm
             Ιd
      0
              1
                             5.1
                                             3.5
                                                              1.4
                                                                              0.2
              2
                             4.9
                                                                              0.2
      1
                                             3.0
                                                              1.4
      2
              3
                             4.7
                                             3.2
                                                              1.3
                                                                              0.2
      3
              4
                             4.6
                                             3.1
                                                              1.5
                                                                              0.2
      4
              5
                             5.0
                                             3.6
                                                                              0.2
                                                              1.4
                             6.7
                                                              5.2
                                                                              2.3
      145
            146
                                             3.0
      146
            147
                             6.3
                                             2.5
                                                              5.0
                                                                              1.9
      147
            148
                             6.5
                                             3.0
                                                              5.2
                                                                              2.0
      148
            149
                             6.2
                                             3.4
                                                              5.4
                                                                              2.3
      149
            150
                             5.9
                                                                              1.8
                                             3.0
                                                              5.1
                    Species
      0
                Iris-setosa
      1
               Iris-setosa
      2
               Iris-setosa
      3
               Iris-setosa
      4
               Iris-setosa
```

145 Iris-virginica

146 Iris-virginica

147 Iris-virginica

148 Iris-virginica

149 Iris-virginica

[150 rows x 6 columns]

```
[99]: iris_sepal = iris.groupby('Species')[["SepalLengthCm", "SepalWidthCm"]].mean()
iris_sepal
```

```
[99]:
                        SepalLengthCm SepalWidthCm
       Species
                                5.006
       Iris-setosa
                                               3.418
       Iris-versicolor
                                 5.936
                                               2.770
                                6.588
                                               2.974
       Iris-virginica
[100]: | iris_petal = iris.groupby('Species')[["PetalLengthCm", "PetalWidthCm"]].mean()
       iris_petal
[100]:
                        PetalLengthCm PetalWidthCm
       Species
                                 1.464
                                               0.244
       Iris-setosa
       Iris-versicolor
                                4.260
                                               1.326
                                5.552
                                               2.026
       Iris-virginica
      3.6
           Reshaping
      3.7
           stack()
[101]: # Ponemos como columna de index la de especies, asi aplicaremos los datos segunu
        ⇔de que
       # especie sean:
       reiris = iris.set_index('Species', append=True)
       reiris
[101]:
                            Id SepalLengthCm SepalWidthCm PetalLengthCm \
           Species
       0
           Iris-setosa
                             1
                                           5.1
                                                         3.5
                                                                         1.4
                             2
                                           4.9
                                                         3.0
                                                                         1.4
       1
           Iris-setosa
       2
           Iris-setosa
                             3
                                           4.7
                                                         3.2
                                                                         1.3
       3
           Iris-setosa
                             4
                                           4.6
                                                         3.1
                                                                         1.5
           Iris-setosa
                             5
                                           5.0
                                                         3.6
                                                                         1.4
                                           6.7
                                                         3.0
                                                                         5.2
       145 Iris-virginica 146
       146 Iris-virginica
                           147
                                           6.3
                                                         2.5
                                                                         5.0
       147 Iris-virginica
                           148
                                           6.5
                                                         3.0
                                                                         5.2
       148 Iris-virginica
                                           6.2
                                                         3.4
                                                                         5.4
                           149
                                           5.9
                                                         3.0
                                                                         5.1
       149 Iris-virginica
                          150
                           PetalWidthCm
           Species
           Iris-setosa
                                     0.2
       0
       1
           Iris-setosa
                                     0.2
           Iris-setosa
                                     0.2
       2
                                     0.2
           Iris-setosa
       3
           Iris-setosa
                                     0.2
```

145	Iris-virginica	2.3
146	Iris-virginica	1.9
147	Iris-virginica	2.0
148	Iris-virginica	2.3
149	Iris-virginica	1.8

[150 rows x 5 columns]

```
[102]: stack_iris = reiris.stack(future_stack=True)
stack_iris
```

[102]:		Species		
	0	Iris-setosa	Id	1.0
			${\tt SepalLengthCm}$	5.1
			${\tt SepalWidthCm}$	3.5
			${\tt PetalLengthCm}$	1.4
			${\tt PetalWidthCm}$	0.2
				•••
	149	Iris-virginica	Id	150.0
			${\tt SepalLengthCm}$	5.9
			${\tt SepalWidthCm}$	3.0
			${\tt PetalLengthCm}$	5.1
			PetalWidthCm	1.8

Length: 750, dtype: float64

Nos muestra los datos apilados según la especie y las longitudes de los pétalos y sépalos.

Para desapilar usaremos el método unstack.

```
[103]: unstack_iris = reiris.unstack()
unstack_iris
```

[103]:		Id			SepalLengthCm	\
	Species	Iris-setosa	Iris-versicolor	Iris-virginica	Iris-setosa	
	0	1.0	NaN	NaN	5.1	
	1	2.0	NaN	NaN	4.9	
	2	3.0	NaN	NaN	4.7	
	3	4.0	NaN	NaN	4.6	
	4	5.0	NaN	NaN	5.0	
		•••	•••	•••	•••	
	145	NaN	NaN	146.0	NaN	
	146	NaN	NaN	147.0	NaN	
	147	NaN	NaN	148.0	NaN	
	148	NaN	NaN	149.0	NaN	
	149	NaN	NaN	150.0	NaN	

Species Iris-versicolor Iris-virginica Iris-setosa Iris-versicolor

 ${\tt SepalWidthCm}$

0	NaN	NaN	3.5	NaN
1	NaN	NaN	3.0	NaN
2	NaN	NaN	3.2	NaN
3	NaN	NaN	3.1	NaN
4	NaN	NaN	3.6	NaN
	•••	•••	•••	•••
	•••	•••	***	***
145	NaN	6.7	NaN	 NaN
145	NaN	6.7	NaN	NaN
145 146	NaN NaN	6.7 6.3	NaN NaN	NaN NaN
145 146 147	NaN NaN NaN	6.7 6.3 6.5	NaN NaN NaN	NaN NaN NaN

${\tt PetalLengthCm}$

Iris-setosa Iris-versicolor Iris-virginica Species Iris-virginica 0 NaN 1.4 NaN NaN 1 NaN 1.4 NaN NaN2 NaN 1.3 NaN NaN 3 1.5 NaN ${\tt NaN}$ NaN4 1.4 NaN NaN ${\tt NaN}$. . 5.2 145 3.0 ${\tt NaN}$ ${\tt NaN}$ 146 2.5 ${\tt NaN}$ ${\tt NaN}$ 5.0 147 3.0 ${\tt NaN}$ ${\tt NaN}$ 5.2 148 NaN 5.4 3.4 NaN 149 3.0 ${\tt NaN}$ NaN 5.1

PetalWidthCm

Species	Iris-setosa	Iris-versicolor	Iris-virginica
0	0.2	NaN	NaN
1	0.2	NaN	NaN
2	0.2	NaN	NaN
3	0.2	NaN	NaN
4	0.2	NaN	NaN
	•••	•••	•••
145	NaN	NaN	2.3
146	NaN	NaN	1.9
147	NaN	NaN	2.0
148	NaN	NaN	2.3
149	NaN	NaN	1.8

[150 rows x 15 columns]

3.8 pivot_table()

```
[104]: # Agrupación de datos de especie por media:
       # Podemos añadir: df, values="D", index=["A", "B"], columns=["C"]
       iris_pivot = pd.pivot_table(iris, index='Species')
       iris_pivot
[104]:
                           Id PetalLengthCm PetalWidthCm SepalLengthCm \
       Species
       Iris-setosa
                         25.5
                                        1.464
                                                      0.244
                                                                     5.006
                         75.5
                                        4.260
                                                                     5.936
       Iris-versicolor
                                                      1.326
                        125.5
                                        5.552
                                                      2.026
                                                                     6.588
       Iris-virginica
                        {\tt SepalWidthCm}
       Species
       Iris-setosa
                               3.418
       Iris-versicolor
                               2.770
       Iris-virginica
                               2.974
[105]: # Agrupación de datos de especie por media:
       iris_pivot2 = pd.pivot_table(iris, index='Species', aggfunc="sum")
       iris_pivot2
[105]:
                          Id PetalLengthCm PetalWidthCm SepalLengthCm \
       Species
       Iris-setosa
                        1275
                                       73.2
                                                      12.2
                                                                    250.3
                                                      66.3
                                                                    296.8
       Iris-versicolor 3775
                                      213.0
       Iris-virginica
                        6275
                                      277.6
                                                     101.3
                                                                    329.4
                        SepalWidthCm
       Species
       Iris-setosa
                               170.9
       Iris-versicolor
                               138.5
                               148.7
       Iris-virginica
[106]: # el parametro values nos ayuda a seleccionar las columnas concretas:
       iris_pivot = pd.pivot_table(iris, values="PetalLengthCm", index='Species')
       iris_pivot
[106]:
                        PetalLengthCm
       Species
                                1.464
       Iris-setosa
       Iris-versicolor
                                4.260
                                5.552
       Iris-virginica
```

3.9 Time Series

```
[107]: # Generamos una serie temporal primero generamos los valores de la fecha de la
       → que quieres partir, creando 15 días consecutivos:
       # Una vez creados ponemos valores aleatorios a esas fechas:
      rng = pd.date_range("6/1/2024 00:00", periods=15, freq="D")
      ts = pd.Series(np.random.randn(len(rng)), rng)
[107]: 2024-06-01
                   -0.288107
      2024-06-02
                    0.370095
      2024-06-03
                   -1.016510
      2024-06-04
                   -0.534900
      2024-06-05
                   0.665725
      2024-06-06
                   -0.030754
      2024-06-07
                   -0.398885
      2024-06-08
                   -0.354273
      2024-06-09
                   -1.640718
      2024-06-10
                   2.034297
      2024-06-11
                   -0.027026
      2024-06-12 -0.654963
      2024-06-13 -0.492587
      2024-06-14
                   -0.274447
                   -1.237346
      2024-06-15
      Freq: D, dtype: float64
      3.10 tz_localize()
[108]: # añadimos la hora al dataframe creado:
      ts_utc = ts.tz_localize("UTC")
      ts_utc
[108]: 2024-06-01 00:00:00+00:00
                                   -0.288107
      2024-06-02 00:00:00+00:00
                                   0.370095
      2024-06-03 00:00:00+00:00
                                  -1.016510
      2024-06-04 00:00:00+00:00
                                   -0.534900
      2024-06-05 00:00:00+00:00
                                   0.665725
      2024-06-06 00:00:00+00:00
                                   -0.030754
      2024-06-07 00:00:00+00:00
                                  -0.398885
      2024-06-08 00:00:00+00:00
                                   -0.354273
      2024-06-09 00:00:00+00:00
                                  -1.640718
      2024-06-10 00:00:00+00:00
                                   2.034297
      2024-06-11 00:00:00+00:00
                                  -0.027026
      2024-06-12 00:00:00+00:00
                                   -0.654963
      2024-06-13 00:00:00+00:00
                                  -0.492587
      2024-06-14 00:00:00+00:00
                                  -0.274447
```

```
Freq: D, dtype: float64
      3.11 tz_convert()
[109]: # Ponemos la franja horaria a la cual nos encontramos:
       ts_utc.tz_convert("Europe/Madrid")
[109]: 2024-06-01 02:00:00+02:00
                                   -0.288107
       2024-06-02 02:00:00+02:00
                                    0.370095
       2024-06-03 02:00:00+02:00
                                   -1.016510
       2024-06-04 02:00:00+02:00
                                   -0.534900
       2024-06-05 02:00:00+02:00
                                   0.665725
       2024-06-06 02:00:00+02:00
                                   -0.030754
       2024-06-07 02:00:00+02:00
                                   -0.398885
       2024-06-08 02:00:00+02:00
                                   -0.354273
       2024-06-09 02:00:00+02:00
                                   -1.640718
       2024-06-10 02:00:00+02:00
                                   2.034297
       2024-06-11 02:00:00+02:00
                                   -0.027026
       2024-06-12 02:00:00+02:00
                                   -0.654963
       2024-06-13 02:00:00+02:00
                                   -0.492587
       2024-06-14 02:00:00+02:00
                                   -0.274447
       2024-06-15 02:00:00+02:00
                                   -1.237346
      Freq: D, dtype: float64
      3.12 offsets.BusinessDay()
      Escogemos de ese periodo de tiempo los que sean laborables, ayuda de offset.BusinnesDay():
[110]: rng
[110]: DatetimeIndex(['2024-06-01', '2024-06-02', '2024-06-03', '2024-06-04',
                      '2024-06-05', '2024-06-06', '2024-06-07', '2024-06-08',
                      '2024-06-09', '2024-06-10', '2024-06-11', '2024-06-12',
                      '2024-06-13', '2024-06-14', '2024-06-15'],
                     dtype='datetime64[ns]', freq='D')
[111]: # se añade 5 como número de días a representar:
       rng = rng + pd.offsets.BusinessDay(5)
[112]: ts = pd.Series(np.random.randn(len(rng)), rng).tz_localize("UTC")
[112]: 2024-06-07 00:00:00+00:00
                                   -1.007800
                                   -0.730140
       2024-06-07 00:00:00+00:00
```

-1.237346

2024-06-15 00:00:00+00:00

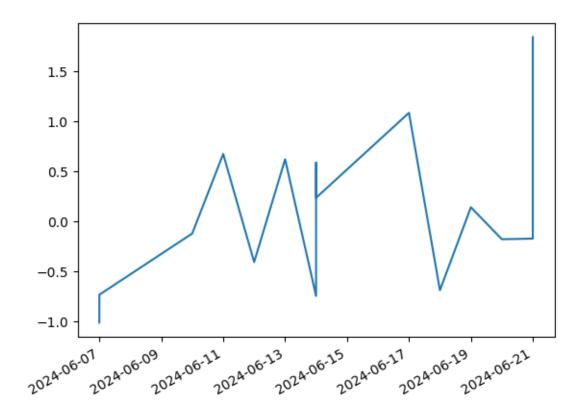
2024-06-10 00:00:00+00:00

2024-06-11 00:00:00+00:00

-0.119705

0.674214

```
2024-06-12 00:00:00+00:00
                                   -0.404627
       2024-06-13 00:00:00+00:00
                                    0.620892
       2024-06-14 00:00:00+00:00
                                   -0.742859
       2024-06-14 00:00:00+00:00
                                    0.587692
       2024-06-14 00:00:00+00:00
                                    0.236711
       2024-06-17 00:00:00+00:00
                                    1.084321
       2024-06-18 00:00:00+00:00
                                    -0.685404
       2024-06-19 00:00:00+00:00
                                    0.142537
       2024-06-20 00:00:00+00:00
                                    -0.176736
       2024-06-21 00:00:00+00:00
                                   -0.170452
       2024-06-21 00:00:00+00:00
                                     1.839676
       dtype: float64
[113]: ts.tz_convert("Europe/Madrid")
[113]: 2024-06-07 02:00:00+02:00
                                   -1.007800
       2024-06-07 02:00:00+02:00
                                   -0.730140
       2024-06-10 02:00:00+02:00
                                    -0.119705
       2024-06-11 02:00:00+02:00
                                    0.674214
       2024-06-12 02:00:00+02:00
                                   -0.404627
       2024-06-13 02:00:00+02:00
                                    0.620892
       2024-06-14 02:00:00+02:00
                                   -0.742859
       2024-06-14 02:00:00+02:00
                                    0.587692
       2024-06-14 02:00:00+02:00
                                    0.236711
       2024-06-17 02:00:00+02:00
                                    1.084321
       2024-06-18 02:00:00+02:00
                                    -0.685404
       2024-06-19 02:00:00+02:00
                                    0.142537
       2024-06-20 02:00:00+02:00
                                   -0.176736
       2024-06-21 02:00:00+02:00
                                    -0.170452
       2024-06-21 02:00:00+02:00
                                    1.839676
       dtype: float64
[114]:
      import matplotlib.pyplot as plt
[115]: ts.plot()
[115]: <Axes: >
```



3.13 Categoricals

	Id	${\tt SepalLengthCm}$	${\tt SepalWidthCm}$	${\tt PetalLengthCm}$	${\tt PetalWidthCm}$	\
0	1	5.1	3.5	1.4	0.2	
1	2	4.9	3.0	1.4	0.2	
2	3	4.7	3.2	1.3	0.2	
3	4	4.6	3.1	1.5	0.2	
4	5	5.0	3.6	1.4	0.2	
•	•••	•••	•••	•••	•••	
L45	146	6.7	3.0	5.2	2.3	
146	147	6.3	2.5	5.0	1.9	
47	148	6.5	3.0	5.2	2.0	
148	149	6.2	3.4	5.4	2.3	
.49	150	5.9	3.0	5.1	1.8	
		Species				
)	I	ris-setosa				
	I	ris-setosa				
2	I	ris-setosa				
3	Т	ris-setosa				

```
Iris-setosa
       145 Iris-virginica
       146 Iris-virginica
       147 Iris-virginica
       148 Iris-virginica
       149 Iris-virginica
       [150 rows x 6 columns]
[117]: iris.dtypes
[117]: Id
                          int64
       SepalLengthCm
                        float64
       SepalWidthCm
                        float64
       PetalLengthCm
                        float64
       PetalWidthCm
                        float64
       Species
                         object
       dtype: object
[118]: # Convertimos la columna Species en categoricas:
       iris["Species"] = iris["Species"].astype("category")
       iris.dtypes
[118]: Id
                           int64
                         float64
       SepalLengthCm
       SepalWidthCm
                         float64
       PetalLengthCm
                         float64
       PetalWidthCm
                         float64
       Species
                        category
       dtype: object
      3.14 rename_categories()
[119]: # Renombrar la columna especie con solo la especie que es:
       new_categories = ["setosa", "versicolor", "virginica"]
       iris["Species"] = iris["Species"].cat.rename_categories(new_categories)
       iris
[119]:
                 {\tt SepalLengthCm SepalWidthCm PetalLengthCm PetalWidthCm}
                                                                               Species
             Ιd
                           5.1
                                                                        0.2
       0
              1
                                          3.5
                                                         1.4
                                                                                setosa
       1
              2
                           4.9
                                          3.0
                                                         1.4
                                                                        0.2
                                                                                setosa
       2
              3
                           4.7
                                          3.2
                                                         1.3
                                                                        0.2
                                                                                setosa
       3
              4
                           4.6
                                          3.1
                                                         1.5
                                                                        0.2
                                                                                setosa
       4
              5
                           5.0
                                          3.6
                                                         1.4
                                                                        0.2
                                                                                setosa
```

4

• •	•••	•••	•••	•••	•••	
145	146	6.7	3.0	5.2	2.3	virginica
146	147	6.3	2.5	5.0	1.9	virginica
147	148	6.5	3.0	5.2	2.0	virginica
148	149	6.2	3.4	5.4	2.3	virginica
149	150	5.9	3.0	5.1	1.8	virginica

[150 rows x 6 columns]

3.15 set_categories()

[120]:		Id	SepalLengthCm	${\tt SepalWidthCm}$	PetalLengthCm	${\tt PetalWidthCm}$	Species \
	0	1	5.1	3.5	1.4	0.2	setosa
	1	2	4.9	3.0	1.4	0.2	setosa
	2	3	4.7	3.2	1.3	0.2	setosa
	3	4	4.6	3.1	1.5	0.2	setosa
	4	5	5.0	3.6	1.4	0.2	setosa
		•••	•••	•••	•••		
	145	146	6.7	3.0	5.2	2.3	virginica
	146	147	6.3	2.5	5.0	1.9	virginica
	147	148	6.5	3.0	5.2	2.0	virginica
	148	149	6.2	3.4	5.4	2.3	virginica
	149	150	5.9	3.0	5.1	1.8	virginica

[150 rows x 7 columns]

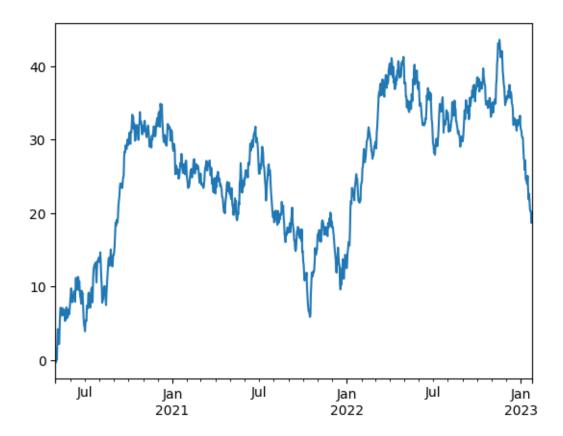
3.16 sort_values()

```
[121]: # Colocar las filas según los valores de una columna, en este caso ordenamos
        ⇔por la especie (spc):
       iris.sort_values(by="spc", ascending=False)
                                                                               Species \
[121]:
             Id SepalLengthCm SepalWidthCm PetalLengthCm PetalWidthCm
                                          3.0
                                                         5.1
                                                                        1.8 virginica
       149
           150
                           5.9
       111
           112
                           6.4
                                          2.7
                                                         5.3
                                                                        1.9 virginica
       122 123
                           7.7
                                          2.8
                                                         6.7
                                                                        2.0 virginica
       121
                           5.6
                                                                        2.0 virginica
           122
                                          2.8
                                                         4.9
       120
                           6.9
                                          3.2
                                                         5.7
           121
                                                                        2.3 virginica
                                                                         •••
       31
             32
                           5.4
                                          3.4
                                                         1.5
                                                                        0.4
                                                                                setosa
       30
             31
                           4.8
                                          3.1
                                                         1.6
                                                                        0.2
                                                                                setosa
       29
                           4.7
                                          3.2
                                                                        0.2
             30
                                                         1.6
                                                                                setosa
       28
             29
                           5.2
                                          3.4
                                                         1.4
                                                                        0.2
                                                                                setosa
       0
             1
                           5.1
                                          3.5
                                                         1.4
                                                                        0.2
                                                                                setosa
           spc
       149
             2
       111
             2
       122
             2
       121
             2
       120
             2
       . .
            . .
       31
             0
       30
       29
             0
       28
             0
       0
             0
       [150 rows x 7 columns]
[122]: # Agrupamos para que nos muestre cuantos valores tenemos de cada uno, para ellou
       ⇔usamos observed=False en groupby,
       # Incluyen categorias vacias si las hubiera:
       iris.groupby("spc", observed=False).size()
[122]: spc
       0
            50
            50
       1
       2
            50
       dtype: int64
```

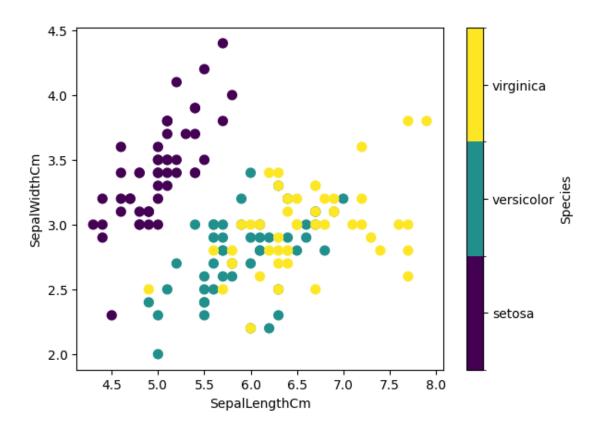
3.17 Plotting

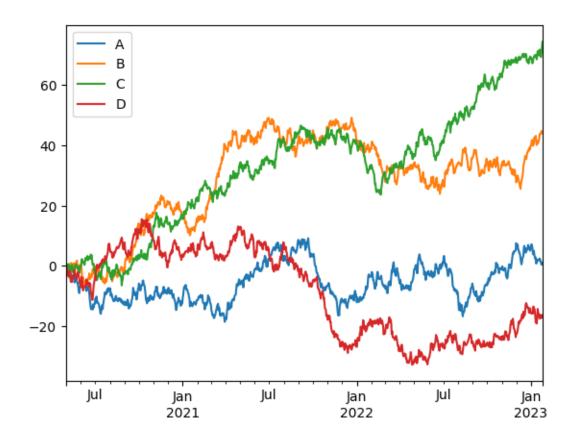
Pandas usa de manera interna matplotlib, simplemente importando la librería y pasando el dataframe a .plot() te genera el gráfico:

[123]: <Axes: >



[124]: <Axes: xlabel='SepalLengthCm', ylabel='SepalWidthCm'>





Creado por: Isabel Maniega